

Rapport de projet de préparation métier

Détection et classification de la maladie d'Alzheimer à l'aide de réseaux de neurones convolutifs 2D et 3D.

Réalisé par

**Amri Siwar
Ellefi Alaa**

Encadrant

Mr. Riadh Abdelfattah

2024-2025

Table des matières

Introduction	1
1 Aperçu du projet	2
1.1 Problématique	2
1.2 État de l’art	2
1.3 Jeu de données	3
1.3.1 Description	3
1.3.2 Prétraitement et Modification des Données pour les CNN 2D	3
1.3.3 Prétraitement et Modification des Données pour les CNN 3D	4
2 Description des Modèles	5
2.1 BrainNet2D	5
2.2 CNN pré-entraînés	6
2.3 Architectures des CNN 3D	7
2.3.1 Architecture du BrainNet3D	7
2.3.2 Architecture de BrainNet3D Modifié	7
2.3.2.1 ResNet 3D et DenseNet 3D	8
3 Résultats	9
3.1 Description des métriques utilisées	9
3.2 Évaluation de la performance	10
3.2.1 Performances des CNN 2D	10
3.2.2 Performances des CNN 3D	12
Conclusion	12

Table des figures

1.1	Répartition des classes	3
1.2	Des instances de chaque classe	4
1.3	Images de l'hippocampe droit pour l'échantillon 1 de la base OASIS	4
2.1	Architecture du modèle BrainNet 2D	5
2.2	Densenet121	6
2.3	Comparaison entre les paramètres des modèles	7
2.4	Architecture de BrainNet3D	7
2.5	Architecture Resnet3D	8
3.1	Matrice de confusion de Brainnet2D	10
3.2	Exemples de cas sains, de formes très légères d'Alzheimer et de formes légères à modérées	11
3.3	Matrice de confusion de Resnet-50 3D	12

Introduction

La maladie d'Alzheimer est une pathologie neurodégénérative progressive qui touche des millions de personnes dans le monde. Elle se manifeste par un déclin cognitif irréversible, évoluant généralement vers une perte complète d'autonomie. L'un des principaux défis liés à cette maladie réside dans la difficulté d'un diagnostic précoce, souvent retardé, ce qui limite les possibilités de prise en charge efficace.

Ce projet a pour objectif de tirer parti des réseaux de neurones convolutionnels (CNN) afin d'améliorer la détection automatique et précise des différents stades de la maladie d'Alzheimer. L'approche repose sur l'analyse d'images par résonance magnétique (IRM) extraites de la base de données OASIS-1. Plusieurs modèles ont été développés et comparés en termes de performance, notamment en évaluant leur précision (accuracy) et leur capacité à discriminer les stades de la maladie, tout en prenant en compte leur complexité architecturale.

Plusieurs modèles ont été évalués, en comparaison avec des approches de référence comme BrainNet2D et BrainNet3D, dans le but d'identifier avec précision les stades de la maladie d'Alzheimer. Les résultats préliminaires montrent que certains modèles préentraînés, tels que VGG16 ou InceptionV3, offrent de meilleures performances que des modèles conçus sur mesure. Par ailleurs, les architectures hybrides CNN-LSTM et certains réseaux 3D, comme une version adaptée de BrainNet3D ou 3D-DenseNet, affichent un fort potentiel. Les travaux futurs viseront à affiner ces modèles et à enrichir les données utilisées, afin d'améliorer encore la précision du diagnostic.

Chapitre 1

Aperçu du projet

Introduction

DANS ce chapitre, nous présenterons le contexte général du projet ainsi que le processus de préparation, incluant l'analyse des technologies et des outils nécessaires, et une description synthétique de la base de données utilisée.

1.1 Problématique

Selon l'Organisation mondiale de la santé (OMS), la maladie d'Alzheimer affecte environ 35 millions de personnes à travers le monde. Les traitements efficaces restent limités, en partie parce que les interventions sont souvent initiées trop tardivement dans l'évolution de la maladie. Ce retard contribue à l'échec de nombreux essais cliniques et souligne l'importance cruciale d'un diagnostic précoce pour améliorer les chances de succès thérapeutique. Par ailleurs, la pénurie mondiale de spécialistes en neurodégénérescence complique davantage la prise en charge rapide et adaptée des patients. Aujourd'hui, seulement 5 % des cas détectés au stade précoce bénéficient d'un diagnostic à temps.

1.2 État de l'art

Le diagnostic de la maladie d'Alzheimer repose actuellement en grande partie sur l'expertise des professionnels de santé. Les méthodes traditionnelles d'apprentissage automatique, comme les SVM ou la régression logistique appliquées aux images IRM, offrent des résultats précis d'environ 80 %, mais ne parviennent pas à exploiter pleinement la complexité des données

En revanche, les réseaux de neurones convolutionnels (CNN) tels que ResNet-50 ou Inception-ResNet-v2 ont montré des performances supérieures à 90 % sur certaines bases d'images, mais leur efficacité sur OASIS-1 reste à confirmer. D'autres architectures comme DenseNet ou VGG ont également donné de bons résultats. Des modèles plus légers et spécialisés, comme BrainNet2D, montrent qu'il est possible d'obtenir de bonnes performances avec des architectures moins complexes.

Enfin, de nouvelles architectures 3D comme 3D-DenseNet ou BrainNet3D ont montré un potentiel prometteur dans d'autres domaines médicaux et méritent d'être explorées davantage dans le contexte de la maladie d'Alzheimer.

1.3 Jeu de données

1.3.1 Description

Le jeu de données OASIS-1 comprend des scans IRM cérébraux de 416 individus âgés de 18 à 96 ans, dont 100 atteints de la maladie d'Alzheimer. Il inclut également des informations démographiques et cliniques, avec un déséquilibre marqué entre les cas cognitivement normaux et ceux présentant différents stades de démence.




FIGURE 1.1 – Répartition des classes

1.3.2 Prétraitement et Modification des Données pour les CNN 2D

Dans le cadre de l'entraînement des modèles convolutifs 2D, des images issues de coupes spécifiques d'IRM ont été extraites à partir du dataset OASIS1. Plus précisément, les tranches sélectionnées se situent entre les indices 60 à 80 ainsi que 100 à 120, correspondant à des régions cérébrales informatives. Ces volumes ont ensuite été convertis en fichiers image au format JPG, un format adapté au traitement par des architectures de type CNN.

Pour assurer la fiabilité de l'évaluation et prévenir toute forme de contamination entre les ensembles de données, la division a été réalisée à l'échelle des sujets. Ainsi, l'ensemble des images provenant d'un même patient a été affecté exclusivement à un seul groupe (entraînement, validation ou test). Cette méthodologie permet d'éviter l'introduction de biais, notamment dus à la forte similarité entre les tranches successives d'un même volume IRM, qui risqueraient sinon de compromettre la validité des résultats.

Un total de 86 426 images au format JPG a été extrait des volumes IRM, puis uniformément redimensionné en 224×224 pixels afin d’assurer la compatibilité avec la plupart des architectures convolutives utilisées. Une exception a été faite pour le modèle InceptionV3, qui requiert des entrées au format 299×299 pixels en raison de sa structure interne particulière.

Pour remédier au déséquilibre entre les classes, des techniques d’augmentation de données ont été appliquées, telles que des rotations, un renforcement des contours et une détecturisation des images.

Après traitement, la distribution des échantillons était la suivante :

- **Jeu d’entraînement** : environ 47 289 images de sujets sains, 12 000 cas de stade très léger, et 12 000 de stade léger/modéré.
- **Jeu de validation** : 13 178 images saines, 3 190 très légers, et 1 284 légers/modérés.
- **Jeu de test** : 6 658 images saines, 1 223 très légers, et 478 légers/modérés.




FIGURE 1.2 – Des instances de chaque classe

1.3.3 Prétraitement et Modification des Données pour les CNN 3D

Les volumes 3D ont été extraits des fichiers compressés au format .tar à l’aide de la plateforme **Clinica**, couramment utilisée dans les études en neuroimagerie. En raison de la taille restreinte du jeu de données, un prétraitement a été appliqué, incluant une *régression non linéaire*, la *segmentation de la matière grise*, et la conversion finale des volumes en *tenseurs* adaptés à l’entraînement des modèles profonds.

Pour limiter le surapprentissage, l’entraînement et les tests des architectures 3D ont été réalisés exclusivement sur **l’hippocampe droit**. Ce choix repose sur des recherches indiquant que cette région, impliquée dans le traitement de l’information spatiale, est souvent touchée dès les premiers stades de la maladie d’Alzheimer.

La taille des images a ainsi été réduite de $121 \times 45 \times 121$ à $30 \times 40 \times 30$. Un exemple visuel est présenté à la Figure ci-dessous.

Les données ont été réparties en deux ensembles : **80 %** pour l’entraînement/validation et **20 %** pour le test. Le premier regroupait 300 échantillons (242 sains, 37 atteints très légèrement, 21 modérément), contre 77 pour le second (62 sains, 8 très légers, 7 modérés). Un équilibrage a été effectué selon l’âge, le sexe et le diagnostic afin d’assurer la représentativité des groupes.




FIGURE 1.3 – Images de l’hippocampe droit pour l’échantillon 1 de la base OASIS

Chapitre 2

Description des Modèles

Introduction

DANS ce chapitre, nous détaillons l'architecture des modèles déployés, en précisant leur structure interne, les choix de conception adoptés, ainsi que leurs principaux avantages et limitations.

2.1 BrainNet2D

BrainNet représente un modèle de réseau de neurones convolutifs (CNN) allégé qui consiste de cinq blocs convolutionnels. Chaque bloc est une suite de structure séquentielle incluant une couche de convolution, une normalisation par batch, une activation ReLU ainsi qu'une opération de max pooling. Cette Architecture modulaire nous ramène à une extraction efficace des caractéristiques et laisse la complexité computationnelle relativement faible.




FIGURE 2.1 – Architecture du modèle BrainNet 2D

Les premières couches capturent des caractéristiques simples, comme des contours ou des bords. En revanche, les couches plus profondes extraient des motifs plus complexes qui peuvent être cruciaux pour poser des diagnostics pertinents. De plus, l'architecture se caractérise par une digestion hiérarchique. Cela favorise une meilleure généralisabilité, mais aussi une résolution réduite. Une autre conséquence de GAP est la perte de détails spatiaux. Cela peut limiter la capacité de distinguer les caractéristiques fines qui sont nécessaires pour une évaluation digne de confiance du système nerveux.

2.2 CNN pré-entraînés

Après avoir soumis le modèle **BrainNet2D** à l'évaluation, notre étude étendue inclut plusieurs autres architectures CNN 2D bien connues : **DenseNet121**, **InceptionV3**, et **VGG16**. Nous traitons ces modèles pour leur architecture variée, en termes de profondeur, plage de noyau, et connectivité, de sorte que nous testions leurs performances sur les images IRM cérébrales de classification AD à l'aide du jeu de données OASIS.

Ainsi, l'architecture DenseNet121 a été adaptée pour la classification de la maladie d'Alzheimer en insérant une transformation en deux étapes linéaires dans son classifieur : une première étape qui abaisse la taille des features dans la moitié de leurs dimensions en utilisant une fonction d'activation ReLU, et ensuite une seconde étape qui les projette sur le problème de classification de la maladie. L'adaptement préserve la connectivité dense et la supervision profonde, améliore la propagation du gradient et conduit à la réutilisation des features tout en gardant un nombre limité de paramètres entraînables (526 mille sur un total de 7,5 millions), pour une taille de modèle d'environ 30 Mo.




FIGURE 2.2 – Densenet121

En outre, on a adapté le modèle **InceptionV3** à ce contexte d'imagerie médicale en ajoutant une transformation linéaire en deux étapes dans son classifieur, ce qui améliore la différentiation des caractéristiques en réduisant les dimensions d'un tiers. De plus, ceci a permis d'ajuster les classifieurs pour renforcer la propagation du gradient et la stabilité. Fait pour une entrée de 299×299 pixels, il comprend 25,9 millions de paramètres au total, dont 1,6 million entraînaibles, et a une taille d'environ 103,761 Mo.

D'autre part, le modèle VGG16 a subi une optimisation pour la détection de la maladie d'Alzheimer en ajoutant deux couches linéaires dans la phase finale de classification, où le premier réduit les dimensions d'un facteur de moitié puis les mappes sur les classes cibles pour renforcer l'extraction des caractéristiques. Le modèle final consiste en total 142 millions de paramètres, 8,4 millions sont entraînaibles et ramenant à une taille de 570,629 Mo.




FIGURE 2.3 – Comparaison entre les paramètres des modèles

2.3 Architectures des CNN 3D

2.3.1 Architecture du BrainNet3D

En termes de modèles de référence pour le CNN 3D, le modèle de référence est l'architecture binaire **BrainNet3D**. C'est en fait fondé sur l'architecture **BrainNet2D**, mais étendue à une dimension de plus. Par conséquent, BrainNet3D hérite également du premier l'ensemble des couches convolutionnelles. Cette architecture garantit une certaine complexité de l'extraction des caractéristiques, mais les limites des choix architecturaux du modèle initial également héritées.




FIGURE 2.4 – Architecture de BrainNet3D

2.3.2 Architecture de BrainNet3D Modifié

Par suite, on a retravaillé le design de BrainNet3D pour qu'on puisse améliorer les performances et optimiser la robustesse de notre modèle initial : les couches *Global Average Pooling* et *Dense* ont été remplacées par une couche *Dropout*. Puis, trois paires successives de couches linéaires et d'activations *ReLU*. Et finalement, on aura une couche linéaire supplémentaire. On vise à travers cette modification de renforcer la capacité non linéaire du réseau, selon les standards établis en apprentissage profond.

Par ailleurs, des améliorations spécifiques ont été appliquées aux blocs convolutionnels pour mieux contrôler le surapprentissage. Les couches *ReLU* internes ont été supprimées afin de simplifier la structure, et la couche *MaxPooling* classique a été remplacée par une *Custom-MaxPool 3D*, intégrant un *padding* dynamique pour un traitement plus flexible des volumes d'entrée.

Au final, une amélioration notable du modèle a été réalisée en étendant sa profondeur, en passant de cinq à sept blocs convolutionnels. Cette extension a renforcé sa capacité à capter des représentations complexes en enrichissant la phase d'extraction de caractéristiques. Le nouvel agencement repose sur une montée progressive du nombre de canaux : 8, 16, 32, 64, 128, 256 puis 512, assurant une gradation efficace dans l'apprentissage des détails. Chacune des couches exploite un noyau de convolution en trois dimensions ($3 \times 3 \times 3$), ce qui permet de préserver la finesse de l'analyse volumique à chaque niveau du réseau.

2.3.2.1 ResNet 3D et DenseNet 3D

Dans le cadre de ce projet, des architectures tridimensionnelles ont été exploitées pour des tâches de classification à partir d'IRM cérébrales. Les modèles retenus, **3D ResNet** et **3D DenseNet**, constituent des extensions en trois dimensions de réseaux convolutionnels initialement développés pour le traitement d'images 2D..

Les **3D ResNet** reposent sur l'utilisation de blocs résiduels, qui facilitent la circulation du gradient dans les réseaux profonds et permettent un entraînement plus stable. L'intégration de la normalisation par lot et de la fonction d'activation *LeakyReLU* améliore la robustesse du modèle et atténue les problèmes de disparition du gradient.

Les **3D DenseNet**, quant à eux, se distinguent par leurs connexions denses entre couches, assurant un transfert efficace et continu des caractéristiques. Cette organisation favorise la détection de motifs complexes, souvent nécessaires pour une interprétation fine en imagerie médicale. L'architecture comprend également des couches de transition pour ajuster les dimensions des données, ainsi que l'application de *DropOut* pour limiter le surapprentissage et améliorer la généralisation.




FIGURE 2.5 – Architecture Resnet3D

Chapitre 3

Résultats

Introduction

DANS cette partie, nous allons examiner les performances de nos modèles selon les métriques choisies afin d'évaluer nos résultats finaux.

3.1 Description des métriques utilisées

Pour évaluer la performance de nos modèles CNN 2D multiclassés sur les jeux de validation et de test, nous avons utilisé plusieurs métriques complémentaires, chacune apportant un éclairage particulier sur différents aspects de la classification :

- **Précision (Accuracy)** : C'est la proportion totale de prédictions correctes, toutes classes confondues. Elle donne une mesure globale de la performance du modèle, mais peut être trompeuse lorsque les classes sont déséquilibrées.
- **Précision équilibrée (Balanced Accuracy)** : Cette métrique calcule la moyenne des sensibilités (rappels) de chaque classe, compensant ainsi les effets du déséquilibre des classes. Elle est particulièrement utile dans notre cas, où certaines catégories sont sous-représentées.
- **Courbe ROC et Aire Sous la Courbe (AUC) avec approche One-Versus-Rest (OVR)** : La courbe ROC illustre la capacité du modèle à distinguer une classe donnée des autres. L'approche OVR consiste à traiter chaque classe indépendamment, ce qui permet d'évaluer la discrimination classe par classe. L'AUC mesure la qualité globale de cette discrimination.
- **Sensibilité (Recall ou True Positive Rate)** : La sensibilité mesure la capacité du modèle à identifier correctement les cas positifs, ici les patients atteints de la maladie d'Alzheimer. Une sensibilité élevée est cruciale pour minimiser les faux négatifs, c'est-à-dire les cas mal diagnostiqués.
- **Spécificité (True Negative Rate)** : Cette métrique évalue la capacité du modèle à reconnaître correctement les cas négatifs, c'est-à-dire les individus sains. Une bonne spécificité réduit le nombre de faux positifs, évitant ainsi des diagnostics erronés chez des personnes non malades.

En combinant ces métriques, nous obtenons une évaluation complète et équilibrée des performances de nos modèles, garantissant à la fois une bonne discrimination des classes et une gestion adaptée des déséquilibres dans les données.

3.2 Évaluation de la performance

3.2.1 Performances des CNN 2D

La comparaison de VGG16 et de BrainNet2D montre des différences significatives dans leur capacité à détecter les stades précoces de la maladie d'Alzheimer. Le premier modèle a correctement classé les deux cas testés, ce qui montre qu'il peut facilement distinguer entre les stades de développement de la maladie. En revanche, BrainNet2D a mal classé ces cas, ce qui indique son incapacité à reconnaître les signes précurseurs d'une éventuelle dégénérescence cérébrale.

En revanche, le modèle VGG16, malgré une précision globale plus faible (0,607), présente la meilleure précision équilibrée (0,759) parmi les modèles, ce qui souligne sa fiabilité.




FIGURE 3.1 – Matrice de confusion de Brainnet2D

Cette contre-performance de BrainNet2D peut s'expliquer par un manque de sophistication dans l'extraction des caractéristiques pertinentes à partir des IRM. Le modèle semble avoir du mal à capter les signaux subtils associés aux formes très légères ou modérées de la maladie. En revanche, VGG16 bénéficie d'un avantage significatif lié à son pré-entraînement sur le dataset ImageNet, ce qui renforce sa capacité à extraire des caractéristiques discriminantes même dans un contexte médical.

De manière générale, tous les modèles testés ont montré une amélioration dans l'identification des cas d'Alzheimer par rapport à un modèle de base, mais une limite persiste concernant la détection des formes très légères de la maladie. Ces formes présentent en effet des similarités visuelles importantes avec les cerveaux sains, notamment en raison de l'absence de déformations marquées sur les IRM. Cela rend leur distinction plus difficile et augmente le risque d'erreurs de classification.

En revanche, les cas légers à modérés présentent une atrophie plus prononcée, notamment au niveau de l'hippocampe, ce qui facilite leur identification par les modèles. Cette différence souligne l'importance d'utiliser des architectures capables de capter des altérations fines dans les images cérébrales, notamment pour améliorer la détection précoce de la maladie d'Alzheimer.




FIGURE 3.2 – Exemples de cas sains, de formes très légères d’Alzheimer et de formes légères à modérées

Le modèle **DenseNet121** a obtenu une **exactitude globale** (*accuracy*) de **85,38 %**, ce qui indique qu’il a correctement classé environ 85 % des échantillons du jeu de test. Cependant, cette métrique peut être trompeuse en cas de déséquilibre entre les classes.

C’est pourquoi l’**exactitude équilibrée** (*balanced accuracy*) est plus significative ici, avec une valeur très élevée de **94,88 %**. Elle reflète une performance équilibrée du modèle sur l’ensemble des classes, même si certaines sont sous-représentées.

Parmi les autres métriques importantes :

— **Sensibilité** (*recall*) : **98,89 %**

Cela signifie que le modèle identifie très bien les cas positifs, en ratant très peu de patients atteints de la maladie. C’est un point crucial en contexte médical.

— **Spécificité** : **90,88 %**

Le modèle reconnaît également très bien les cas négatifs, ce qui évite les fausses alertes.

— **Fonction de perte sur le test** (*test loss*) : **0,5917**

Cette valeur indique une bonne généralisation, sans surapprentissage notable.

La **matrice de confusion** ci-dessous permet de mieux visualiser les performances du modèle sur les trois classes (notées ici C0, C1 et C2) :

	Prédit C0	Prédit C1	Prédit C2
Vrai C0	1474	148	849
Vrai C1	108	9600	376
Vrai C2	606	651	4920

- La classe 1 (la plus représentée) est remarquablement bien prédite, avec 9600 cas bien classés.
- La classe 0 montre des confusions avec la classe 2, avec 849 cas mal classés.
- La classe 2 présente également des erreurs, notamment avec les classes 0 et 1, mais reste globalement bien identifiée.

Enfin, la **courbe ROC** montre une **aire sous la courbe (AUC)** très élevée, proche de **0,97**. Cela signifie que le modèle possède un excellent pouvoir de discrimination entre les classes, avec très peu d’erreurs dans ses prédictions binaires.

DenseNet121 offre des performances remarquables, notamment grâce à une sensibilité très élevée, une bonne spécificité, et une excellente capacité à généraliser. Il s’agit donc d’un candidat très prometteur pour la détection automatique de la maladie d’Alzheimer à différents stades.

3.2.2 Performances des CNN 3D

Parmi les architectures 3D testées, le modèle BrainNet3D de base a présenté une précision globale satisfaisante, mais une précision équilibrée nettement inférieure, révélant un déséquilibre entre la sensibilité et la spécificité. Cela montre qu'il détecte bien les cas sains, mais manque de finesse pour identifier les stades précoces de la maladie d'Alzheimer.

En comparaison, les modèles plus profonds comme ResNet-50, ResNet-101 ou encore DenseNet-169 ont démontré une meilleure capacité à repérer les changements subtils dans les IRM, en particulier au niveau de l'hippocampe. Ces modèles ont ainsi montré une meilleure sensibilité et une amélioration de la précision pour les stades légers à modérés. Toutefois, cette progression s'est accompagnée d'une réduction notable de la spécificité, illustrant le compromis entre la détection fine et le risque de faux positifs.

Par ailleurs, une version modifiée du modèle BrainNet3D avec seulement 7 blocs (contre 10 initialement) a amélioré les performances. Cette simplification a probablement permis de réduire les problèmes de gradients et d'overfitting, en facilitant l'apprentissage.

De manière générale, les configurations optimales des modèles ResNet se sont révélées les plus efficaces, grâce à leurs connexions résiduelles, qui facilitent le passage de l'information et évitent l'apprentissage de couches peu utiles.




FIGURE 3.3 – Matrice de confusion de Resnet-50 3D

Les modèles développés ont permis une amélioration notable de l'identification des cas d'Alzheimer par rapport au modèle de base, notamment en ce qui concerne la différenciation des stades de la maladie. Toutefois, les performances se sont révélées inférieures pour les formes très légères de la maladie, comparées aux formes légères à modérées.

Cette baisse de performance s'explique par la nature subtile des altérations visibles dans les IRM des patients très légèrement atteints. Ces cas ne présentent souvent que de légères déformations, ce qui les rend visuellement très proches des sujets sains. En revanche, les patients aux stades légers à modérés présentent des pertes plus significatives, notamment au niveau de l'**hippocampe**, facilitant ainsi leur identification.

En moyenne, les modèles ont correctement identifié environ **85,7%** des cas légers à modérés. Cependant, leur spécificité réduite et les erreurs fréquentes dans la classification des sujets sains indiquent que les ressemblances visuelles entre les cerveaux sains et les formes très légères d'Alzheimer ont fortement contribué aux erreurs de classification, ce qui limite l'efficacité du diagnostic précoce.

Conclusion

Dans ce rapport, nous avons comparé plusieurs architectures CNN en versions 2D et 3D, en particulier BrainNet, appliquées à l'imagerie neuro-médicale. Les modèles BrainNet, qu'ils soient en 2D ou en 3D, ont une architecture légère qui favorise une complexité réduite. Cependant, ils présentent un risque de surapprentissage et peuvent rencontrer des difficultés à capturer des motifs complexes essentiels pour un diagnostic précis.

En revanche, les architectures plus avancées et pré-entraînées, comme VGG16 et DenseNet, offrent une capacité supérieure à extraire des caractéristiques fines et à généraliser davantage grâce à leur profondeur et à leur conception optimisée. Ces modèles ont surpassé les performances des versions simplifiées telles que BrainNet.

Pour les travaux futurs, il serait intéressant d'explorer des architectures hybrides combinant la légèreté des modèles BrainNet 2D/3D avec la richesse des modèles pré-entraînés, tout en intégrant des mécanismes de régularisation avancés pour limiter le surapprentissage. L'utilisation de données multimodales et l'application de l'apprentissage auto-supervisé pourraient améliorer la robustesse et la précision dans divers contextes cliniques. Enfin, une validation sur des bases de données plus étendues et variées permettra d'évaluer la scalabilité et la généralisation des modèles proposés.

Bibliographie

- [1] **Google Colab** : <https://ledatascientist.com/google-colab-le-guide-ultime/>
- [2] **CLINICADL - Preprocessing Notebook** : https://colab.research.google.com/github/aramis-lab/clinicadl_handbook/blob/main/notebooks/preprocessing.ipynb
- [3] **Kaggle - OASIS Dataset** : <https://www.kaggle.com/datasets/ninadaithal/imagesoasis>
- [4] **PLOS ONE – OASIS Dataset Article** : <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0186071>
- [5] **Resnet50** : <https://blog.roboflow.com/what-is-resnet-50/>
- [6] **Binary Cross-Entropy** : <https://www.analyticsvidhya.com/blog/2021/03/binary-cross-entropy-log-loss-for-binary-classification/>
- [7] **F1 score** : <https://en.wikipedia.org/wiki/F-score>